

P O R T F O L I O

주요 연구 내용 및 이력

핵심 이력사항 KEY ACHIEVEMENTS

연구 분야 예지보전(PHM) · 시계열 예측 · 엣지 컴퓨팅 & 모델 경량화

저널 논문 SCIE Q1 · 2편

- Edge-compatible SOH Estimation
Journal of Energy Storage · 제1저자 (2025.11)
- BVINN: Butler-Volmer Informed NN
Energy · 제2저자 (2025.10)

국내 학회 · 특허

- 한국신뢰성학회 학술대회 2편
우수논문발표상 1건 (포스터 부문, 2025.06)
- 특허 출원 1건 (공동발명)
차량 엣지 배터리 상태 예측 모델 (2026.02)

국제 학회 IEEE PHM · 2편

- Hybrid Compression for Edge BMS · 제1저자
IEEE PHM Conference (2025)
- ProbSparse Informer 기반 SOH 예측
IEEE PHM · Best Paper Award

수상

- Factory Hack Korea 2025 최우수상
산업통상자원부 주관 (2025.12)
- IEEE PHM Best Paper · 신뢰성학회 우수발표상
국제·국내 학술대회 수상

김태이

한양대학교 산업경영공학과 (Graduate School of Hanyang University)

엣지 호환형 SOH 예측을 위한 하이브리드 지식 증류 및 단계적 모델 경량화

Edge-compatible SOH estimation for Li-ion batteries via hybrid knowledge distillation and model compression

Journal of Energy Storage (SCIE Q1, JCR 상위 14%) | 제 1저자 | 2025.11

문제 정의

딥러닝 기반 SOH 예측 모델은 높은 정확도를 보이지만 엣지 BMS 환경에서 직접 구동 불가

높은 연산량

차량 BMS 탑재 불가

클라우드 의존

엣지 디바이스에 탑재 가능하도록 모델 경량화 필요

연구 동기

한계 ①
엣지 BMS 고려 연구 부족

기존 연구는 클라우드 환경
전제로한 성능 향상에
집중함

한계 ②
통합 압축 연구 부재

지식증류, 프루닝, 양자화
세 가지 경량화 기법을
통합한 연구 부재

한계 ③
표준 평가 지표 부재

자연 시간, 메모리 등 표준
평가 체계가 확립되지 않음

수행 역할 및 기여도

제1저자 — 연구 전 과정 주도

- KD→Pruning→Quantization 3단 압축 파이프라인 설계
- 출력+잠재공간 관계를 함께 모방하는 Hybrid KD 제안
- NASA-CALCE 벤치마크 및 Raspberry Pi 4B 실패포 검증

활용 기술

Knowledge Distillation(Hybrid) · Structured Pruning · Quantization
Time-series modeling, ONNX 변환, Raspberry Pi 실증

이슈 및 해결방안

- 정확도↔크기 트레이드오프 → 3단 점진 압축으로 교사 대비 99% 축소하며 R^2 0.97대 유지
- 압축 순서 민감 → Ablation으로 KD→Prune→Quant가 최적임을 입증
- 실제 동작 미검증 우려 → Raspberry Pi 실패포로 83.5배 작고 18.7배 빠른 추론 확인
- 센서 노이즈 → 0~100% 노이즈에서도 안정적 R^2 (강건성 검증)




그림 1. 제안 모델 경량화 프레임워크

제안 파이프라인

교사 모델
LSTM (451 KB)

① 하이브리드 지식 증류
교사 모델의 정답과 잠재 표현을
모방

② 구조적 프루닝
중요도 낮은 뉴런을
제거 후 파인튜닝

③ 동적 양자화
모델 가중치를
32bit → 8bit 변환

경량 모델
LSTM (5.4KB)

물리지식 기반 딥러닝을 활용한 배터리 SOH 예측

Enhancing battery SOH Prediction with Butler-Volmer informed neural networks in data-scarce environments

Energy (SCIE Q1, JCR 상위 4%) | 제 2저자 | 2025.10

개요

BMS는 전류·전압·온도만으로 SOH를 추정해야 하나, 수명시험 데이터가 부족하면 기존 ML은 과적합·일반화 한계를 보임. Butler-Volmer 전기화학식을 신경망 손실에 정규화 항으로 직접 결합해 데이터 부족 환경에서도 물리적으로 일관된 예측을 확보.

수행 역할 및 기여도

제2저자 — 벤치마크·Ablation 실험 전담

- 데이터 사용량을 100→70→30%로 줄여가며 BVINN과 MLP·LSTM·GRU 성능을 비교
- 데이터 부족 환경에서의 강건성을 정량 검증

활용 기술

- Butler-Volmer 방정식 손실 정규화 · Coulomb counting · MLP/LSTM/GRU · 시퀀스 30/70/100% 데이터 축소 Ablation · OPTUNA 튜닝 · Wilcoxon 부호순위 검정 · PyTorch

이슈 및 해결방안

- 데이터 부족 시 기존 ML 급격한 성능 저하(B0018 R² 0.19) → 물리식 결합으로 BVINN R² 0.98 회복
- 30% 데이터에서도 전 셀 우위 유지 → Wilcoxon 검정으로 통계적 유의성 확인




그림 2. 제안 모델 학습 프레임워크

표 1. BVINN vs LSTM · 데이터 사용량별 R²

배터리	100% 데이터		70% 데이터		30% 데이터	
	LSTM	BVINN	LSTM	BVINN	LSTM	BVINN
B0005	0.97	0.96	0.96	0.98	0.96	0.98
B0006	0.95	0.96	0.98	0.97	0.96	0.97
B0007	0.75	0.80	0.70	0.89	0.69	0.83
B0018	0.19	0.98	0.95	0.97	0.91	0.95

On-Premise 경량 AI 품질검사 시스템 (해커톤)

Factory Hack Korea 2025 최우수상

산업통장자원부 주관 · 담당 역할: 경량화 / Few-shot 적응학습 전략 설계 | 2025.12

개요

비전 검사는 도입돼 있으나 불량 원인 분석·신규 불량 대응은 전문가에 의존하고, 국내 제조 중소기업 44%는 고성능 GPU가 없어 AI 적용에 제약이 큼. 자원이 제한된 현장에서도 동작하는 On-Premise 경량 비전 AI 에이전트를 설계.

수행 역할 및 기여도

경량화 전략 설계·실험 / Few-shot 적응학습 전략 수립

· 결함 유형·위치 제시와 로컬 LLM 원인 설명을 잇는 에이전트 흐름 설계

활용 기술

Swin-Transformer · 구조적 프루닝 · 동적 양자화 · 분류+세그멘테이션 · 로컬 LLM · Few-shot Learning

이슈 및 해결방안

- 자원 제약(GPU 부재) → 구조적 프루닝+양자화로 Swin-Transformer 약 59% 경량화, 정확도 오차 5% 이내
- 신규 불량 대응 어려움 → Few-shot 적응학습(기존+신규 혼합)으로 망각 없이 신규 결함 학습
- 단순 판정의 한계 → 분류·세그멘테이션으로 위치 제시 + 로컬 LLM이 원인·대응 설명



[실시간 감지]	[AI의 불량 탐지]	[작업자의 불량 유형 입력]	[AI의 추가 학습]	[정확도 향상]
컨베이어 라인에서 제품을 카메라가 실시간 촬영	AI가 기존에 학습된 범위 내에서 불량 유형을 식별 모델에 없는 새로운 불량은 "UNKNOWN"으로 표시	작업자는 "UNKNOWN"으로 표시된 이미지에 실제 불량 요소를 직접 입력하여 라벨 제공	AI Agent는 작업자가 제공한 새로운 결함 라벨을 즉시 추가 학습하여 모델에 반영	현장에서 반복적인 입력을 통해 결함 탐지 정확도를 지속적으로 향상

그림 2. 제안 AI 에이전트 흐름 (분류·세그멘테이션 → 로컬 LLM 원인 설명)




그림 3. Few-shot 학습 — 샘플 수에 따른 신규 결함 정확도